

把大模型的能力， 教给真正能部署的小模型

一份从论文机制走到工程选型的中文互动课件。核心问题不是“谁分数最高”，而是：你要转移什么能力、能看到教师的什么信号、最后部署在哪里？

本课结束后，你应该能回答

1. 普通 SFT、logit KD、CoT 蒸馏到底差在哪？
2. “conditional distillation”可以具体指什么？
3. 哪些模型只是开放权重，哪些能完整复现？
4. 1B、4B、8B、32B 应该分别选谁？

5

方法家族

12

可下载模型 / 家族

17

代表方法与最新工作

2026.07

资料截点

先把三个最容易混淆的词拆开

蒸馏不是单一算法，而是一组“用教师信号训练学生”的方法。小模型也不一定来自蒸馏。

1

开放权重 ≠ 全流程开源

DeepSeek-R1-Distill 可下载且许可宽松，但原始 80 万条蒸馏数据与完整训练流水线没有全部公开；Open-R1 才补上了较完整的模型、数据、训练与评估链。

2

蒸馏 ≠ 只学最终答案

学生可以学教师的 token 概率、生成回答、推理轨迹、偏好排序、中间表示、多个教师的互补知识，甚至剪枝后如何恢复性能。

3

小模型 ≠ 蒸馏模型

TinyLlama、SmolLM、MobileLLM-R1 等可以主要靠架构、数据和训练配方得到。判断依据应是技术报告是否明确使用教师信号，而不是名字里有没有 “mini”。

本 survey 的口径：把“开源”拆成权重 / 代码 / 蒸馏数据三层；把“conditional”视为条件化或自适应蒸馏的工程总称，而不是一个已经统一定义的学术门类。

用三根轴，定位任何一篇蒸馏工作

AXIS A · TRANSFER

传什么？

- 分布：logits / token 概率
- 行为：回答、工具轨迹、CoT
- 结构：hidden states、关系、表征
- 偏好：排序、critique、reward

AXIS B · ACCESS

能看到什么？

- 白盒：权重、logits、中间层
- 灰盒：top-k 概率或批量推理
- 黑盒：只能拿文本输出
- 多教师：不同架构 / tokenizer

AXIS C · CONDITION

目标何时变化？

- 固定：离线教师数据
- on-policy：跟着学生生成分布变
- 课程式：随训练时间改变教师强度
- 样本式：按难度、验证结果或预算路由

$$L = \lambda \cdot L_{\text{ground_truth}} + \alpha(t, x) \cdot D(\text{student} \parallel \text{teacher} / \text{assistant}) + \beta \cdot L_p$$

这条式子最重要的不是符号，而是三个选择：监督来源、分布距离、以及系数是否随训练步或样本变化。

CHAPTER 03 · FIVE FAMILIES

五类方法，比“普通 / 特殊 / conditional”更可操作

$P(y|x)$

白盒教师最典型的“普通蒸馏”。

Token / logit distribution matching

让学生在每个 token 上接近教师分布。MiniLLM 用 reverse KL 抑制低概率区域被过度估计；DistiLLM 用 skewed KL 与自适应离线策略；CSD (ICLR 2026) 直接对齐相对 logit 差，绕开 softmax 平滑。

MiniLLM

DistiLLM

Gemma 3

Qwen3

CSD

TRACE

只需要教师能生成文本，最容易扩展。

Response / rationale / trajectory distillation

教师先生成回答或思维链，再用 SFT、偏好学习或 RL 训练学生。DeepSeek-R1-Distill、OpenR1、Phi-4-mini-reasoning 都属于这条主线。关键不在“生成更多”，而在可验证、去污染、去重复和难度配比。

DeepSeek-R1-Distill

Open-R1

Phi-4-mini-reasoning

Distilling Step-by-Step

SKILL

只搬运有用的能力，不追求全能复刻。

Domain / skill / preference distillation

把数学、代码、医疗、检索、embedding、工具使用或对齐偏好做成专项学生。专项模型常能在窄任务超过教师，但边界外能力会明显掉。HuatuogPT-o1 和 EmbeddingGemma 是两个不同例子：前者蒸馏医疗推理数据，后者蒸馏几何 embedding 关系。

HuatuogPT-o1

EmbeddingGemma

DistiLLM-2

FutureMind

$\alpha(t, x)$

教师目标随学生、时间或样本而变。

Conditional / adaptive / on-policy distillation

GKD 用学生自己生成的序列暴露错误；TAID 随训练时间把目标从学生分布逐步移向教师；AMiD 用 α -mixture assistant distribution 调整 mode-seeking 与 mode-covering；FutureMind 按问题阶段注入不同推理先验。

GKD

TAID

AMiD

FutureMind

N→1

结构不一致，或教师不止一个。

Prune-then-distill / cross-tokenizer / knowledge fusion

Minitron 与 Llama 3.2 先从大模型剪出小结构，再用 KD 恢复；FuseLLM 把多个教师的互补分布融合到一个学生；2026 的 Cross-Tokenizer Likelihood Scoring 则让不同 BPE 词表也能做概率级蒸馏。

Minitron

Llama 3.2

FuseLLM / FuseChat

Cross-tokenizer scoring

CHAPTER 04 · MODEL CHOOSER

先说需求，再说模型

这是工程默认值，不是脱离硬件、语言和数据分布的“总榜”。选择后会给出三档建议。

首选

1

Qwen3 小模型家族

通用中文、多语、本地 agent；希望许可宽松且尺寸跨度大。

[打开模型 / 项目 ↗](#)

备选

2

Gemma 3

小尺寸多语、长上下文与 4B 轻量多模态。

[打开模型 / 项目 ↗](#)

Llama 3.2

Arm / mobile 生态、端侧摘要、改写、轻量工具调用。

[打开模型 / 项目 ↗](#)

CHAPTER 05 · OPEN MODEL ATLAS

可下载模型图鉴

卡片中的“全链路”只给模型、蒸馏数据、训练 / 评估代码都能找到的项目。其余统一称“开放权重”，避免过度承诺。

显示 12 / 12 个模型或家族

STRONG-TO-WEAK LOGIT KD

开放权重

Qwen3 小模型家族

0.6B / 1.7B / 4B

Apache 2.0

教师: Qwen3 flagship models

思考 / 非思考双模式；小模型后训练直接蒸馏旗舰模型 logits，仅约四阶段流程 1/10 GPU 小时。

适合：通用中文、多语、本地 agent；希望许可宽松且尺寸跨度大。

注意：训练数据与完整生产流水线未全开。

[模型 ↗](#) [证据 ↗](#)

TOP-256 LOGIT KD + RL

开放权重

Gemma 3

1B / 4B

Gemma Terms

教师: Large IT teacher

预训练采样每 token 256 个 logits；指令模型继续从大型 IT teacher 蒸馏。4B 还支持图像。

适合： 小尺寸多语、长上下文与 4B 轻量多模态。

注意： 不是 OSI 开源许可；训练数据不开放。

[模型 ↗](#) [证据 ↗](#)

STRUCTURED PRUNING + LOGIT KD

开放权重

Llama 3.2

1B / 3B

Llama 3.2 Community

教师: Llama 3.1 8B / 70B

从 8B 单次结构化剪枝，再用 8B / 70B token-level logits 在预训练阶段恢复能力。

适合： Arm / mobile 生态、端侧摘要、改写、轻量工具调用。

注意： 自定义许可证；完整预训练语料与 KD 代码未公开。

[模型 ↗](#) [证据 ↗](#)

800K RESPONSE / COT SFT

开放权重

DeepSeek-R1-Distill

1.5B / 7B / 8B / 14B / 32B / 70B

MIT + 上游许可

教师: DeepSeek-R1

R1 推理数据微调 Qwen2.5-Math、Qwen2.5、Llama 3.x 基座，覆盖从笔记本到多卡服务器。

适合: 数学、代码、逻辑推理；要一个跨度完整的开箱家族。

注意: 原始 80 万样本与完整训练流程没有全部开放。

[模型 ↗](#) [证据 ↗](#)

COT DISTILLATION

开放权重

DeepSeek-R1-0528-Qwen3-8B

8B

MIT

教师: DeepSeek-R1-0528

把新版 R1-0528 的思维链蒸馏到 Qwen3-8B Base；官方报告 AIME 2024 为 86.0。

适合: 单张高显存卡上的强数学 / 竞赛代码推理。

注意: 长思维链会提高延迟；数据与训练代码未全开。

[模型 ↗](#) [证据 ↗](#)

350K VERIFIED TRACES + SFT

全链路

OpenR1-Distill-7B

7B

Apache 2.0

教师: DeepSeek-R1

以 Mixture-of-Thoughts 复现 R1-Distill-7B 能力，数据、配方、训练与评估入口公开。

适合：重视可复现、要改数据混合或继续做 RLVR 研究。

注意：主要英语；不是所有 DeepSeek 原流程的逐项复刻。

[模型 ↗](#) [证据 ↗](#)

VERIFIED SYNTHETIC MATH DISTILLATION

开放权重

Phi-4-mini-reasoning

3.8B

MIT

教师: DeepSeek-R1

约百万道合成数学题、每题 8 个 rollout，经正确性筛选形成约 30B token 数学内容。

适合：4B 级英语数学、教育辅导、轻量科学推理。

注意：偏英语和数学；完整合成数据未作为训练集发布。

[模型 ↗](#) [证据 ↗](#)

TEMPORALLY ADAPTIVE INTERPOLATED KD

开放权重

TAID-LLM-1.5B

1.5B

Apache 2.0

教师: Qwen2-72B-Instruct

训练初期靠近学生分布，随后逐步移向教师，缓解 capacity gap、mode averaging 与 collapse。

适合：研究自适应 KD；需要一个可直接比较的 1.5B checkpoint。

注意：官方明确称实验原型，不建议关键生产环境。

[模型 ↗](#) [证据 ↗](#)

PRUNE-THEN-DISTILL

模型 + 方法代码

NVIDIA Minitron

4B / 8B

NVIDIA Open Model License

教师: Nemotron-4 15B / Llama 3.1 8B / NeMo

剪 embedding、attention heads、FFN 或深度，再用持续预训练蒸馏恢复；模型与工具 notebook 可用。

适合：想从既有模型家族系统地产出多个小尺寸基座。

注意：数据语料并非完整开放；许可证需单独审阅。

[模型 ↗](#) [证据 ↗](#)

FuseLLM / FuseChat

7B

依 checkpoint

教师：多个开源 LLM / Chat 模型

先对齐不同教师的 token 分布 / 输出，再把互补能力融合进单个学生；模型、数据和代码公开。

适合：多教师各有强项、没有单一绝对教师，或研究模型融合。

注意：工程复杂度和上游许可证会随教师数量增加。

[模型 ↗](#) [证据 ↗](#)

HuatuogPT-o1-7B

7B

Apache 2.0

教师：GPT-4o / DeepSeek-R1 + medical verifier

中英医疗复杂推理模型；医疗可验证问题、reasoning SFT 数据、模型与仓库公开。

适合：医疗 RAG、领域推理研究和数据配方复现。

注意：不可直接用于临床诊断；教师并非全部开放。

[模型 ↗](#) [证据 ↗](#)

EmbeddingGemma

308M

Gemma Terms

教师: Gemini Embedding

多语 text embedding; 通过 encoder-decoder 初始化与几何蒸馏捕获大模型表征关系。

适合: 端侧 RAG、语义检索、向量数据库; 不需要生成式对话。

注意: 教师为闭源 Gemini Embedding; 不是生成 LLM。

[模型 ↗](#) [证据 ↗](#)

CHAPTER 06 · METHOD MATRIX

如果你要自己蒸馏，先看这张表

Response / CoT SFT

教师访问: 文本输出

学生采样: 否

Tokenizer: 不要求

解决问题: 最便宜地搬运行为与推理风格

开放状态: **Open-R1** 配方

首选场景: API / 开放权重教师, 专项任务

MiniLLM

教师访问: 完整 logits

学生采样: 是

Tokenizer: 通常是

解决问题: reverse KL, 缓解生成分布低概率过估计

开放状态: 代码 / 数据 / **checkpoint**

首选场景: 白盒自回归 KD 基线

GKD

教师访问：学生序列上的教师 logits

学生采样：是

Tokenizer：通常是

解决问题：纠正 exposure bias 与学生真实错误

开放状态：TRL 已实现

首选场景：可在线调用强教师

DistiLLM / 2

教师访问：logits + 学生输出

学生采样：混合

Tokenizer：通常是

解决问题：skewed KL、自适应 off-policy、对比式 KD

开放状态：官方代码

首选场景：指令、代码、偏好、VLM 扩展

TAID

教师访问：教师 logits

学生采样：可选

Tokenizer：是

解决问题：用时间自适应中间分布跨越 capacity gap

开放状态：论文 + 模型

首选场景：教师远强于学生、训练不稳

AMiD

教师访问：教师 logits

学生采样：兼容多种

Tokenizer：是

解决问题：以 α -mixture 统一 assistant distribution

开放状态：ICLR 2026 + 代码

首选场景：要控制 mode seeking / covering

CSD

教师访问：原始 logits

学生采样：可叠加

Tokenizer：是

解决问题：对齐相对 logit 差，避免 softmax 平滑

开放状态：ICLR 2026 论文

首选场景：追求更高 fidelity-diversity

Cross-tokenizer scoring

教师访问：教师概率

学生采样：支持

Tokenizer：不要求

解决问题：把不同 BPE 词表映射到同一概率空间

开放状态：ICLR 2026 + 代码

首选场景：跨模型家族、缩小端侧词表

FuseLLM

教师访问：多个教师分布 / 输出

学生采样：离线为主

Tokenizer：可不同

解决问题：融合多个开源教师的互补知识

开放状态：模型 / 数据 / 代码

首选场景：没有单一绝对教师

Minitron

教师访问：父模型权重 + logits

学生采样：否

Tokenizer：是

解决问题：剪枝后用 KD 恢复性能

开放状态：模型 + 工具 / notebook

首选场景：已有大模型，要产出同族小尺寸

四条最小可行路线

ROUTE A · BLACK-BOX

只有教师输出：先做可验证的 response / CoT 蒸馏

1. 从真实请求或公开题库抽样，先留独立测试集。
2. 让教师多次采样，保留答案、必要推理和元数据。
3. 用执行器 / 规则 / 检索证据验证；去重、去污染、控长度。
4. 先 SFT，再用正确/错误轨迹做偏好优化或 verifier-RL。

适合：DeepSeek-R1 → Qwen / Llama 学生，数学、代码、医疗等可验证任务。

不要：直接把一条长 CoT 当真值；不要用教师自己给自己打分作为唯一过滤。

ROUTE B · WHITE-BOX

同 tokenizer 且能取 logits：GKD / DistiLLM 起步

1. 用 SFT 或学生初始化建立可用起点。
2. 混合真实数据与学生 on-policy 生成，暴露学生会犯的错。
3. 教师在这些 token 前缀上给分布；先试 skew KL / GKD。
4. capacity gap 大时加入 TAID 或 AMiD 的 assistant distribution。

适合：同模型家族压缩、可同时部署教师和学生的训练环境。

不要：只在教师序列上训练却期待学生自由生成时同样稳定。

ROUTE C · STRUCTURAL

已有大模型：剪枝 → 轻量恢复 → 蒸馏

1. 确定目标硬件约束，再选宽度、深度、头数或 FFN 剪枝。
2. 结构化剪枝并做少量 teacher correction。
3. 用原教师分布继续预训练恢复，再做指令后训练。
4. 量化是最后一层部署优化，不要把它和 KD 混为一谈。

适合：Minitron / Llama 3.2 路线，要保持 tokenizer、生态和模型家族一致。

不要：先随意缩结构，再用少量 SFT 期待恢复全部基础能力。

ROUTE D · CROSS-FAMILY

不同 tokenizer 或多教师：先对齐概率空间

1. 若只取文本，直接做字符串级 response distillation。
2. 若要概率级 KD，使用 ALM / contextual mapping / 2026 BPE scoring。
3. 多个教师先做 task-wise 评估，避免弱教师在强项外拖累。
4. 用 FuseLLM 式融合或路由，保留教师来源与样本标签。

适合：Qwen ↔ Llama ↔ Gemma 跨家族迁移、端侧缩词表、多教师集成。

不要：把不同 tokenizer 的 token id 直接做 KL 对齐。

CHAPTER 08 · 2026 FRONTIER

最新进展：不再只问“用哪个 KL”

2023-24

生成式 KD 的目标函数与 on-policy 问题被系统化

MiniLLM、GKD、DistiLLM 把焦点从分类式 KD 转向自回归生成、学生 rollout 与曝光偏差。

2024

蒸馏进入公开基础模型生产线

Llama 3.2、Minitron、Gemma 2/3 展示剪枝 + KD、预训练 logits 与指令教师如何进入模型家族构建。

2025

推理轨迹蒸馏成为主流

DeepSeek-R1-Distill、Open-R1、Phi-4-reasoning 把长 CoT、可验证过滤和后续 RL 组合成可复用范式。

ICLR 2026

assistant distribution 与跨 tokenizer 成熟

AMiD 系统化 α -mixture；Cross-Tokenizer Likelihood Scoring 用 BPE 递归结构做精确/近似概率转换；CSD 对齐相对 logits。

2026.06

Compress-Distill 研究“先压缩思维链再蒸馏”

用 Qwen3.5-397B-A17B 与 gpt-oss-120B 生成轨迹；压缩可把训练 token 降至原来的 12–30%，但原始轨迹仍保持最高准确率——这是速度/长度与精度的真实交换，不是免费午餐。

接下来

从答案模仿走向机制、交互和部署共同优化

值得追踪：circuit distillation、agent trajectory correction、diffusion LLM 轨迹蒸馏、以及按样本难度动态分配教师与思考预算。

CHAPTER 09 · EVALUATION & RISK

一个蒸馏项目真正失败，通常不是 loss 写错

① 能力

任务准确率、生成质量、校准、长文本

② 效率

首 token 延迟、吞吐、峰值显存、输出长度

③ 泛化

新领域、难度外推、多语言、对抗提示

④ 合规

教师许可、数据来源、PII、可追溯性

▼ 为什么学生可能学到“像在推理”，却没有真正更会推理？

文本轨迹监督首先复制的是行为分布。若数据不可验证、难度太低或风格高度重复，学生容易学会冗长模板。最小修正是：可执行验证、多样化问题、保留失败轨迹、同时评估最终答案与 token / 时间成本。

▼ 教师越大越好吗？

不一定。capacity gap 过大时，学生难以匹配尖锐或多峰的教师分布。Gemma 3 的消融显示，短训练期小教师可能更好，训练足够久大教师优势才反转；TAID / AMiD 正是在处理中间分布与训练稳定性。

▼ 为什么只用离线教师数据会失效？

训练时学生只看教师走过的正确前缀，推理时却会进入自己的错误前缀。GKD 和 DistiLLM 的 on-policy / adaptive off-policy 设计让教师在学生真实访问的状态上纠错。

▼ “MIT / Apache”是不是就能放心商用？

仍需检查上游 base model、教师输出条款、训练数据和具体模型卡。例如 Qwen 派生模型通常承接 Apache 2.0，Llama 派生模型还受 Llama Community License 约束；Gemma 与 NVIDIA 也使用各自模型条款。页面标签只作工程筛选，不替代法律审查。

▼ 医疗等专业模型应该怎么用？

HuatuogPT-o1 适合研究医疗推理和 RAG 原型，不应被当成临床诊断系统。专业蒸馏需要领域专家审核、来源可追溯检索、拒答机制和真实工作流评估，不能只看医学考试题。

论文、模型卡与官方仓库

优先列一手资料；模型卡用于确认参数、教师、训练数据与许可证，会议页用于确认发表状态。

- 1 [Qwen3 Technical Report](#) — strong-to-weak logit distillation 与小模型后训练。
- 2 [Gemma 3 Technical Report](#) — top-256 logits、IT teacher、teacher size 消融。
- 3 [Meta Llama 3.2 官方说明](#) — 1B/3B 的结构化剪枝与 logit KD。
- 4 [DeepSeek-R1 官方仓库](#) — 1.5B–70B 蒸馏家族、许可与 80 万样本说明。
- 5 [DeepSeek-R1-0528-Qwen3-8B 模型卡](#) — 8B 新版 CoT 蒸馏与评测。
- 6 [Open-R1 官方仓库](#) — 可复现 SFT 蒸馏、数据与评估。
- 7 [OpenR1-Distill-7B 模型卡](#) — 350k verified traces、Apache 2.0。
- 8 [Phi-4-mini-reasoning 模型卡](#) — DeepSeek-R1 合成数学蒸馏数据。
- 9 [TAID · ICLR 2025](#) 与 [1.5B 模型](#)。
- 10 [NVIDIA Minitron](#) — 剪枝 + KD 的模型、工具与 notebook。
- 11 [FuseLLM](#) 与 [官方仓库](#) — 多教师知识融合。
- 12 [HuatuogPT-o1-7B 模型卡](#) 与 [医疗蒸馏数据](#)。
- 13 [EmbeddingGemma](#) — 308M 多语 embedding 与 geometric distillation。
- 14 [MiniLLM · ICLR 2024](#) — reverse KL 与生成式白盒 KD。
- 15 [GKD · ICLR 2024](#) — on-policy distillation。
- 16 [DistiLLM · ICML 2024](#) — skewed KL 与 adaptive off-policy。
- 17 [DistiLLM-2 · ICML 2025 Oral](#) — 对比式蒸馏及多任务扩展。
- 18 [Distillation Scaling Laws · ICML 2025](#) — 教师 / 学生 compute 分配。
- 19 [AMiD · ICLR 2026](#) 与 [代码](#)。
- 20 [Concrete Score Distillation · ICLR 2026](#) — 相对 logit score matching。
- 21 [Cross-Tokenizer Likelihood Scoring · ICLR 2026](#) 与 [代码](#)。
- 22 [FutureMind · ICLR 2026](#) — 面向检索推理的自适应知识蒸馏。
- 23 [Compress-Distill · 2026-06](#) — 推理轨迹压缩的精度 / 效率权衡。
- 24 [Hugging Face TRL Distillation Trainer](#) — 可落地的现代 KD 训练接口。

开源 LLM 蒸馏教师课

从“传什么”到“选哪个”，再到“怎么训练”。

资料截点 2026-07-16 · 基准成绩以原论文设置为准 · 医疗与许可信息不构成专业意见